

QaTaLViT

Phân đoạn ảnh y khoa kết hợp văn bản với dữ liệu hạn chế

Lưu Huy Minh Quang – 23127016


Trương Quốc Cường – 23127333

Trường Đại học Khoa học Tự nhiên – ĐHQG TP.HCM

- Trong phân đoạn ảnh y khoa, nếu chỉ dùng ảnh làm nguồn tri thức duy nhất, mô hình thường gặp nhiều khó khăn.
- Biên tổn thương có thể mờ, vùng cần phân đoạn nhỏ và dễ lẫn với nền.
- Ảnh y khoa thay đổi theo thiết bị, quy trình chụp và nguồn dữ liệu ở từng nơi.
- Mask phân đoạn rất tốn công gán nhãn vì cần chuyên gia y tế thực hiện.
- Vì vậy, bài toán vừa khó về mặt thị giác, vừa khó do dữ liệu được gán nhãn đầy đủ thường khan hiếm.

- Ảnh y khoa thường đi kèm với mô tả hoặc chẩn đoán lâm sàng ngắn.
- Nguồn văn bản này dễ thu thập hơn mask phân đoạn và thường có cấu trúc tương đối rõ.
- Văn bản có thể chứa thông tin về bên phổi, vị trí tương đối, số vùng tổn thương và mức độ bất thường.
- Do đó, QaTaLViT tận dụng văn bản như tín hiệu ngữ cảnh bổ sung cho ảnh.
- Mục tiêu là dùng văn bản để định hướng đặc trưng ảnh, giúp mô hình tạo mask chính xác hơn.

Kiến trúc QaTaLViT




Tóm tắt tổng quan

- QaTaLViT giữ ảnh làm nguồn quyết định hình dạng mặt nạ, còn văn bản đóng vai trò gợi ý ngữ cảnh và vị trí tổn thương.
- Thực nghiệm dùng hai bộ dữ liệu: QaTa-COV19 với ảnh X-quang ngực và MosMedData+ với CT lát cắt.
- Hệ thống gồm bốn phần: nhánh văn bản, trục CNN kiểu U-Net, các tầng LVFusionStage/ViT, và nhánh EMA/EPI cho dữ liệu chưa nhãn.
- Kết quả chính luôn đọc cùng đối sánh: QaTa-COV19 50% đạt 84.03 / 75.62, cao hơn LViT-T 82.73 / 73.99; MosMedData+ 50% đạt 73.84 / 60.31, nhỉnh hơn LViT-T về Dice nhưng còn thấp hơn về mIoU.
- MosMedData+ được dùng như thí nghiệm mở rộng 50% nhãn, vì đây là mức cân bằng giữa mặt nạ thật và dữ liệu chưa nhãn để kiểm tra pseudo-label.

Phần 1: Nhánh văn bản

Kiến trúc QaTaLViT




Tóm tắt nhánh văn bản

- Đầu vào văn bản là mô tả lâm sàng ngắn, thường chứa thông tin về bên phải, số vùng tổn thương và vị trí tương đối.
- Prompt normalization đưa các cách viết khác nhau về dạng ổn định hơn, giúp mô hình không phải học quá nhiều biến thể ngôn ngữ không cần thiết.
- Prompt sau chuẩn hóa được ánh xạ qua từ vựng, `nn.Embedding` và BiGRU PromptEncoder để tạo token văn bản T .
- Token T không trực tiếp sinh mask, mà được dùng làm tín hiệu điều hướng cho các tầng LVFusionStage.

Phần 2: Trục CNN kiểu U-Net


Kiến trúc QaTaLViT



- CNN encoder là xương sống chính để giữ chi tiết không gian, biên tần thương và cấu trúc cục bộ của ảnh.
- Ảnh đi qua Stem, Down1, Down2, Down3 và Bottom để tạo các đặc trưng nhiều mức $e_1..e_4$ và bottleneck x_5 .
- Decoder dùng $Up4 \rightarrow Up1$ để tăng dần độ phân giải và khôi phục mặt nạ phân đoạn.
- Skip connection nối encoder với decoder, nhưng trong QaTaLViT các skip feature đã được tinh chỉnh bởi văn bản trước khi đưa vào decoder.

Phần 3: LVFusionStage và ViT

A. LVFusionStage: hợp nhất ảnh - văn bản ở từng mức encoder



Tóm tắt LVFusionStage

- LVFusionStage là nơi tương tác ảnh–văn bản diễn ra trực tiếp trên đặc trưng encoder ở nhiều mức.
- Feature CNN D_i được token hóa bằng PatchTokenizer; token ảnh đóng vai trò truy vấn, còn token văn bản T đóng vai trò khóa/giá trị trong CrossLanguageFusion.
- Sau chú ý chéo, token đã hợp nhất đi qua ViT/Transformer block để học quan hệ dài hơn, rồi TokenToSpatial chiếu ngược về feature map.
- Nhờ vậy, văn bản không thay thế CNN, mà điều chỉnh đặc trưng ảnh trước khi đặc trưng đó đi vào skip connection và decoder.

Phần 4: EMA và EPI

B. EMA + EPI: chỉ dùng cho ảnh chưa nhãn


Dữ liệu có nhãn



cập nhật EMA,
không gradient

$$\theta_e \leftarrow \mu\theta_e + (1 - \mu)\theta_s$$

Dữ liệu chưa nhãn



Tóm tắt EMA và EPI

- Với dữ liệu có nhãn, student học trực tiếp từ ground truth; teacher không tạo nhãn cho phần này.
- Với dữ liệu chưa nhãn, EMA teacher là bản trung bình trượt của student, dùng để sinh xác suất dự đoán ổn định hơn.
- EPI lưu và làm mượt xác suất theo từng ảnh qua nhiều lần xuất hiện, giúp pseudo-label ít bị nhiễu bởi một mini-batch riêng lẻ.
- Sau khi lọc theo ngưỡng và độ tin cậy, pseudo-label quay lại huấn luyện student bằng pseudo BCE. Trong thực nghiệm MosMedData+, nhánh này cần rất thận trọng vì teacher yếu có thể làm kết quả xấu đi.

Kết quả trên QaTa-COV19

Phương pháp	25% nhãn	50% nhãn	100% nhãn
LViT huấn luyện lại	78.42 / 68.43	80.32 / 70.60	82.76 / 73.78
LViT-T công bố	80.95 / 71.31	82.73 / 73.99	83.66 / 75.11
QaTaLViT	82.22 / 73.35	84.03 / 75.62	85.28 / 77.25

Mỗi ô là Dice / mIoU (%). QaTaLViT vượt LViT-T công bố ở cả ba mức nhãn.

Phương pháp	Văn bản	Tỷ lệ nhãn	Dice / mIoU (%)
LViT-T chạy lại	Có	50%	68.88 / 55.14
LViT-T công bố	Có	50%	73.56 / 61.05
QaTaLViT tốt nhất	Có	50%	73.84 / 60.31

QaTaLViT 50% nhãn nhỉnh hơn LViT-T 50% về Dice (73.84 so với 73.56), nhưng mIoU còn thấp hơn.

-  Li et al., *LViT: Language meets Vision Transformer in Medical Image Segmentation*, IEEE TMI.
-  Degerli et al., QaTa-COV19 dataset and COVID-19 chest X-ray segmentation benchmark.
-  Morozov et al., MosMedData and MosMedData+ COVID-19 CT segmentation benchmark.
-  Isensee et al., *nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation*.